Universidad de La Sabana

Fundamentos de Redes Neuronales

Proyecto Integrador Final

Diseño, implementación y evaluación de un modelo neuronal aplicado

Actividad 5 – Unidad 3

Predicción de la intención de compra en sesiones de comercio electrónico

Integrantes: Juan Mateo Jaramillo Guerra
Ángel Santiago Díaz Toloza

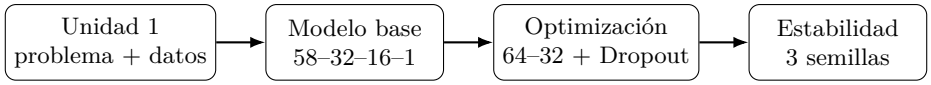
Dataset: Online Shoppers Purchasing Intention – UCI
Docente: Andrés Felipe Beltrán Pulido

Noviembre de 2026

1. Problema, propósito y trazabilidad del proyecto

El proyecto busca responder una pregunta concreta: *¿qué sesiones de navegación de una tienda virtual tienen mayor probabilidad de finalizar en compra?* La variable objetivo es `Revenue`, donde 1 representa compra y 0 ausencia de compra. La salida del modelo se entiende como una probabilidad de apoyo a decisiones de personalización, priorización comercial o asistencia, no como una decisión automática sobre el usuario.

El problema se mantiene desde la Unidad 1, pero el modelo fue evolucionando a partir de evidencia. Primero se construyó una línea base interpretable con regresión logística. Después se implementó una red neuronal densa, se diagnosticó su generalización y se probaron intervenciones de arquitectura y regularización. Finalmente, en Unidad 3 se evaluó la estabilidad de la configuración seleccionada mediante varias semillas y nuevas estrategias de entrenamiento. La lógica completa fue:



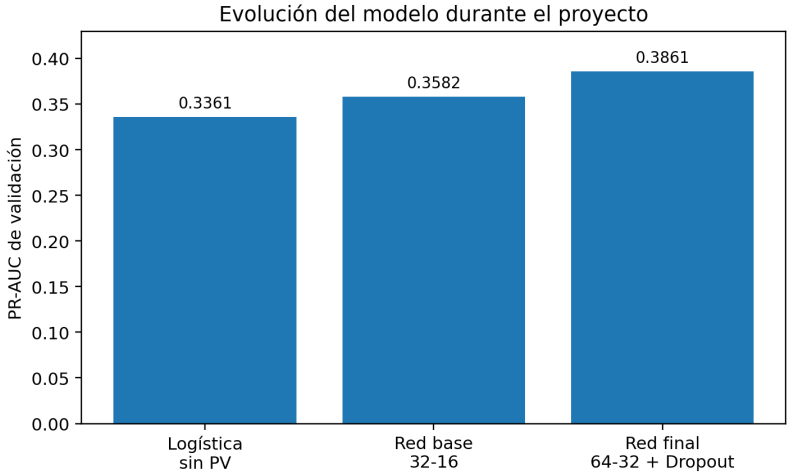


Figura 1: Evolución del PR-AUC de validación desde la línea base logística hasta la red final.

La evolución no se interpreta como una carrera por aumentar una cifra. Cada cambio respondió a un diagnóstico: primero demostrar que había señal no lineal; luego controlar la brecha de generalización; y finalmente comprobar que el resultado no dependiera de una sola inicialización.

2. Dataset, calidad y preparación de datos

Se utilizó el *Online Shoppers Purchasing Intention Dataset* de UCI. El archivo original contiene 12.330 sesiones, 17 variables predictoras y la etiqueta binaria `Revenue`. La clase positiva es minoritaria: 1.908 sesiones terminan en compra (15,47 %) y 10.422 no lo hacen (84,53 %). Por esa razón, una accuracy alta puede ser engañosa y se priorizaron PR-AUC, recall y F1.

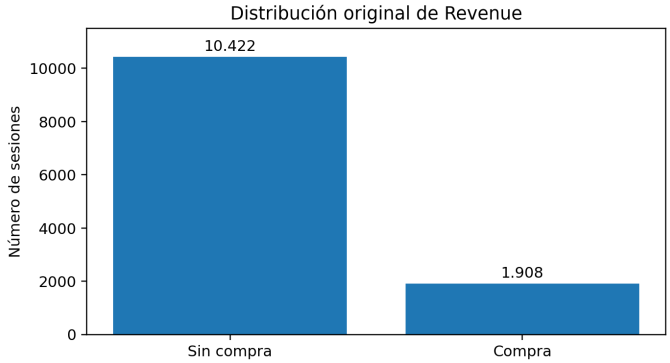


Figura 2: Desbalance original de la variable objetivo.

Antes del modelado se retiraron 125 filas exactamente repetidas, dejando 12.205 sesiones. La partición se hizo de forma estratificada 70/15/15: 8.543 observaciones de entrenamiento, 1.831 de validación y 1.831 de prueba. El preprocesamiento se ajustó únicamente con entrenamiento para evitar fuga de información.

Cuadro 1: Preparación de datos aplicada.

Elemento	Decisión y justificación
Duplicados	Se retiraron antes de dividir para impedir que registros idénticos aparecieran en más de un conjunto.
Conteos y duraciones	Transformación $\log(1+x)$ y estandarización para reducir asimetría y diferencias de escala.
Variables categóricas	One-hot encoding; categorías raras definidas usando solamente entrenamiento.
Desbalance	Pesos de clase calculados con entrenamiento, manteniendo intacta la distribución de validación y prueba.
`PageValues`	Se excluyó mientras no se confirme disponibilidad antes de la compra; usarla podría introducir fuga temporal.

Después del preprocesamiento quedaron 58 características. La base contiene datos estructurados y categóricos, no una secuencia temporal ni una estructura espacial; por eso una red densa es más coherente que forzar una RNN solo por complejidad arquitectónica.

3. Señal predictiva y justificación del enfoque neuronal

La elección de una red multicapa no es únicamente en que fuera más compleja si no desde el análisis inicial se planteó que ciertas variables podían interactuar de forma no lineal. Esa hipótesis se midió posteriormente con `ProductRelated_Duration` y `ExitRates`: las sesiones con duración alta y tasa de salida baja alcanzaron 28,04 % de compra, mientras las de duración baja y salida alta llegaron a 5,52 %.

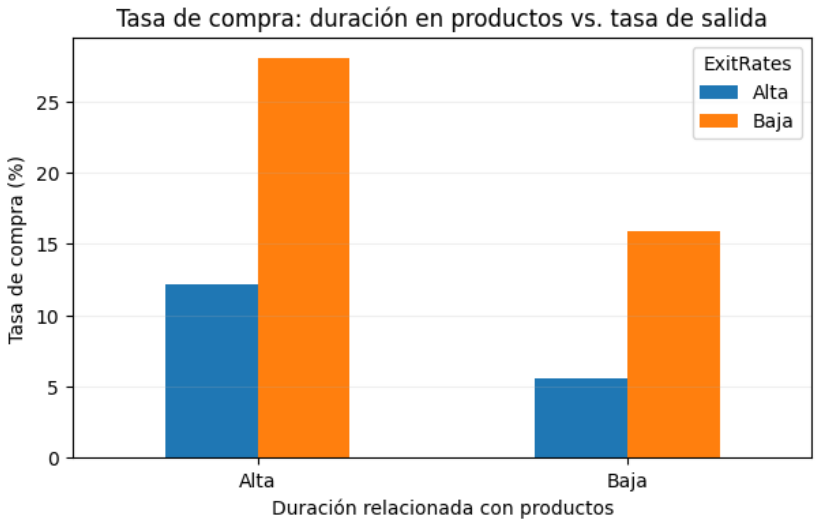


Figura 3: Interacción entre duración en páginas de producto y tasa de salida.

También se cuantificó el papel de `PageValues`. En la regresión logística, el PR-AUC pasó de 0,3361 sin la variable a 0,6284 con ella. El salto es demasiado grande para ignorarlo y sugiere que concentra una señal predictiva muy fuerte.

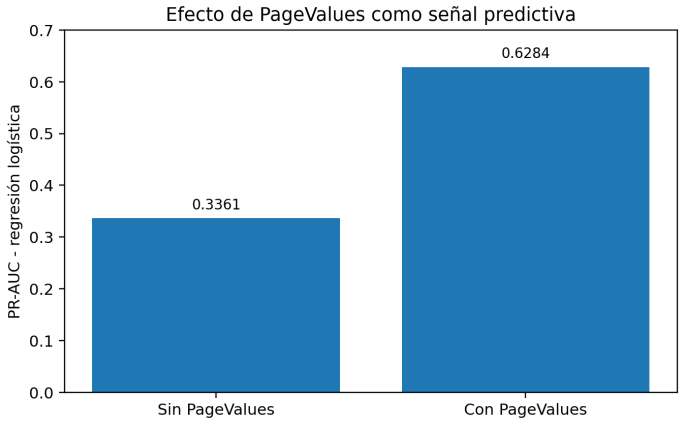
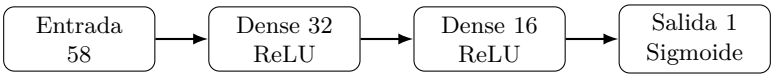


Figura 4: Cambio del PR-AUC de la línea base al incluir `PageValues`.

Sin embargo, el proyecto mantiene una decisión que es no usarla hasta confirmar que esté disponible antes de conocer la compra. Esto ayuda a interpretar un punto que quedó abierto en la retroalimentación anterior: el máximo temprano de validación puede deberse a sobreajuste, pero también a un techo de señal al trabajar sin la variable más informativa. Por tanto, no atribuimos todo el límite del modelo a la optimización.

4. Modelo base y diagnóstico de Unidad 2

El primer modelo neuronal grupal fue una red totalmente conectada 58–32–16–1, con ReLU en capas ocultas, sigmoide en salida, *binary crossentropy*, Adam con learning rate 0,001, batch 32 y pesos de clase. EarlyStopping se alineó con `val_pr_auc` para restaurar los pesos asociados a la métrica prioritaria.



En validación, la red base obtuvo PR-AUC 0,3582, ROC-AUC 0,7733, recall 0,7063 y F1 0,4208. La regresión logística sin `PageValues` obtuvo PR-AUC 0,3361. La red, por tanto, sí capturó señal adicional, pero no dominó todas las métricas. En esta ejecución el mejor PR-AUC de validación apareció en la época 15, por esta razón la lectura del modelo base queda conectada con el mismo split y la misma semilla usados en el notebook final.

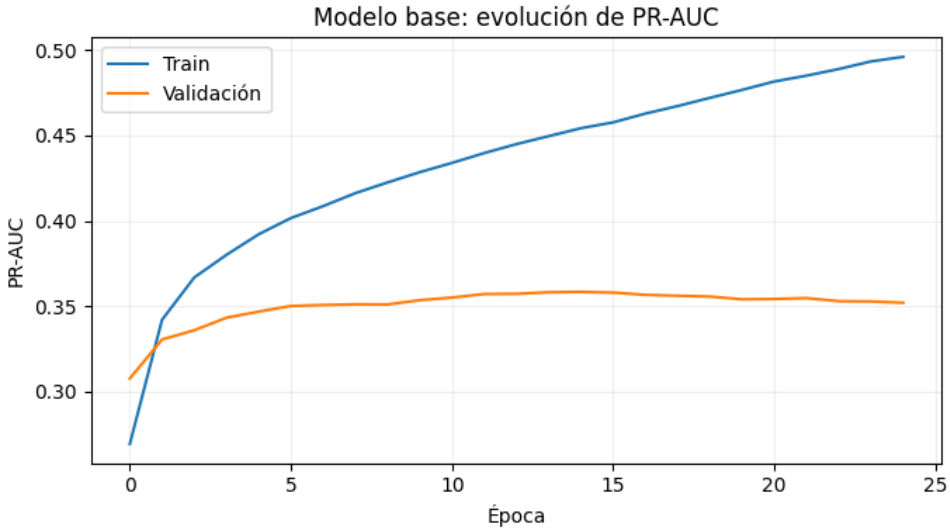


Figura 5: Curvas del modelo base: la mejora en entrenamiento deja de trasladarse a validación.

El diagnóstico fue doble. Primero, existía una brecha de generalización: el entrenamiento continuaba mejorando después de que validación alcanzara su máximo. Segundo, el máximo temprano también era compatible con señal limitada sin

`PageValues`. Esta segunda interpretación se incorpora ahora de forma explícita y evita atribuir el comportamiento a una sola causa.

5. Optimización estratégica en Unidad 2

La siguiente etapa consistió en como Se evaluaron activación, capacidad, regularización y optimizador con cambios controlados. La mejora más clara apareció al aumentar la capacidad de 32–16 a 64–32: el PR-AUC de validación subió de 0,3582 a 0,3846, pero la brecha entre entrenamiento y validación aumentó a 0,1778.

Ese resultado llevó a una intervención específica: Dropout 0,15. Con la misma arquitectura 64–32, el PR-AUC alcanzó 0,3861 y la brecha bajó a 0,1248, aproximadamente 30 % menos que la red amplia sin regularización. L2 redujo parte de la brecha, pero bajó el PR-AUC; RMSprop también redujo desempeño frente a Adam.

Cuadro 2: Evolución técnica del modelo.

Configuración	PR-AUC val	F1 val	Brecha
Red base 32–16	0,3582	0,4208	0,1131
Red amplia 64–32	0,3846	0,4191	0,1778
64–32 + L2 0,0005	0,3742	–	0,1300
64–32 + Dropout 0,15	**0,3861**	0,4159	**0,1248**
64–32 + Dropout + RMSprop	0,3560	0,4008	0,1065

La configuración seleccionada quedó como:

$$\boxed{58 \to 64 \to 32 \to 1}$$

con ReLU, Dropout 0,15, Adam, learning rate 0,001, batch 32 y pesos de clase. No se optimizó el umbral; se mantuvo 0,5 para centrar la comparación en entrenamiento y generalización.

Por esta razón, el notebook final no repite toda la búsqueda de configuraciones: toma la red 64–32 con Dropout 0,15 ya seleccionada y la vuelve a entrenar dentro del flujo completo, de modo que el código de la entrega se concentra en reproducir el modelo final y comprobar su estabilidad.

6. Unidad 3: estabilidad y nuevas intervenciones

La retroalimentación del avance grupal señaló una limitación concreta: la estabilidad se estaba afirmando con una sola corrida. Para cerrarla, en el notebook final se reprodujo la configuración seleccionada con tres semillas de entrenamiento (17, 31 y 53), manteniendo la arquitectura 64–32, Dropout 0,15, Adam, learning rate 0,001 y batch 32. De esta forma la comparación no cambia el modelo, sino que revisa cuánto varía su resultado cuando cambia la inicialización.

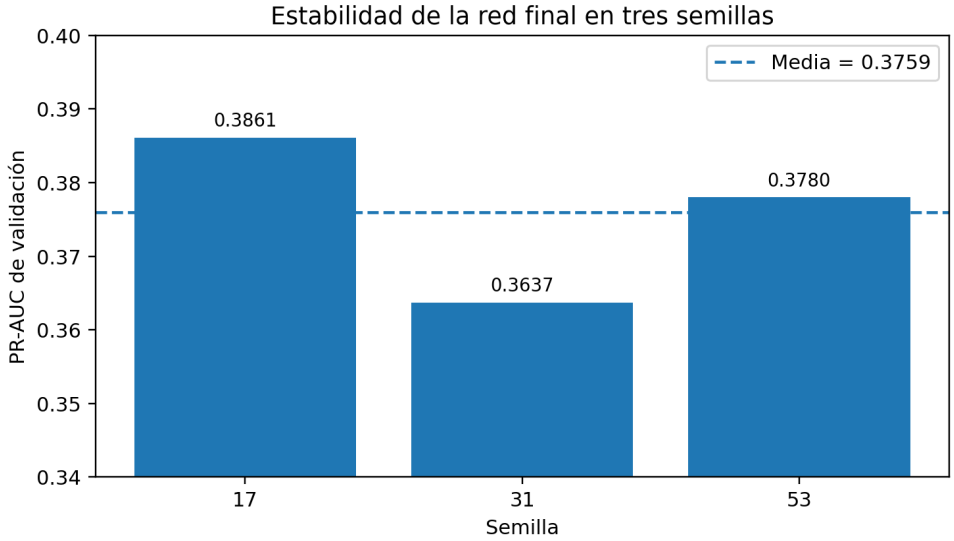


Figura 6: PR-AUC medio y variabilidad entre tres semillas.

El PR-AUC de validación fue 0,3861 con la semilla 17, 0,3637 con la semilla 31 y 0,3780 con la semilla 53. El promedio

quedó en 0,3760 con desviación estándar 0,0113. La conclusión es más sólida que en la etapa anterior: sí existe sensibilidad a la inicialización, pero el resultado ya no se está sosteniendo con una sola corrida.

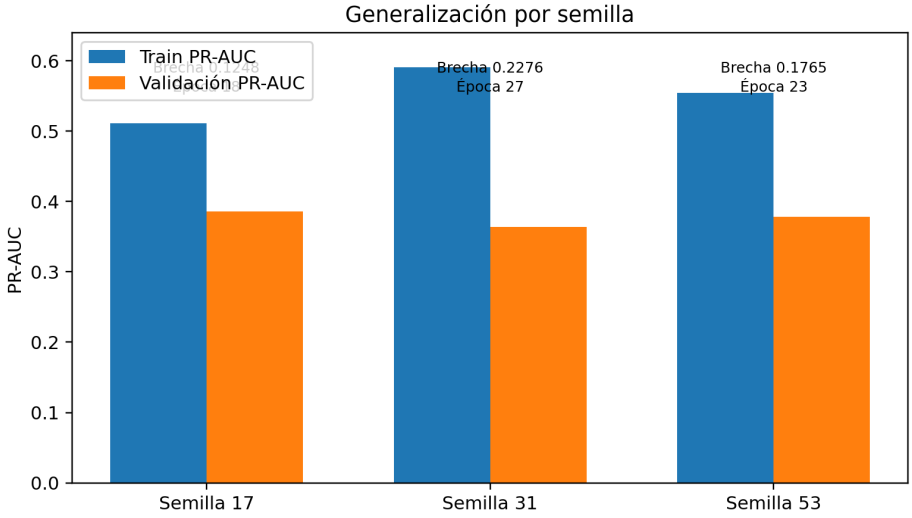


Figura 7: Brecha de generalización y mejor época promedio.

La brecha entre entrenamiento y validación fue 0,1248, 0,2276 y 0,1765 para las tres semillas, mientras las mejores épocas fueron 18, 27 y 23. Por esta razón no afirmamos que la red tenga un comportamiento idéntico en cada ejecución, pero sí podemos medir esa variación y dejar de tratar una sola corrida como evidencia suficiente. El F1 medio fue 0,4179 y el recall medio 0,7075, lo que permite revisar la estabilidad no solo desde PR-AUC sino también desde el comportamiento de la clase positiva.

7. Evaluación final del desempeño

Una vez cerradas las decisiones, el conjunto de prueba se utilizó sin introducir nuevos ajustes. La comparación final se hizo con umbral 0,5 para la regresión logística y para la red.

Cuadro 3: Comparación final sobre prueba.

Modelo	Acc.	Prec.	Recall	F1	ROC-AUC	PR-AUC
Logística	0,6412	0,2594	**0,6993**	0,3784	0,7354	0,3091
Red final	**0,6827**	**0,2872**	0,6958	**0,4065**	**0,7690**	**0,3451**

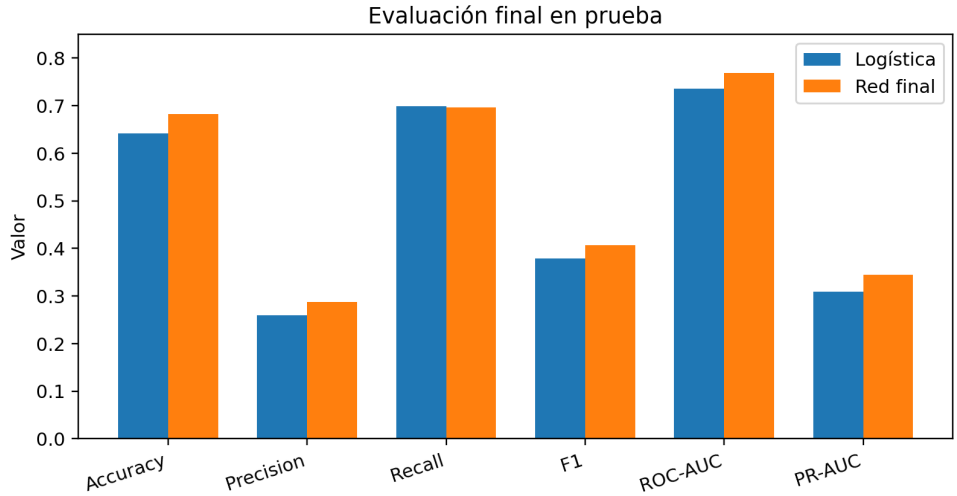


Figura 8: Desempeño final de la regresión logística y la red neuronal.

La red mejora PR-AUC en 0,0360 puntos, cerca de 11,6 % relativo, y también mejora F1, precision, ROC-AUC y accuracy. El recall queda prácticamente empatado y ligeramente por debajo de la logística. Esta diferencia se mantiene en la conclusión porque evita afirmar que la red domina todos los criterios.

La matriz de confusión de la red muestra 199 verdaderos positivos, 87 falsos negativos, 494 falsos positivos y 1.051 verdaderos negativos. En un problema con 15,6 % de positivos, la precisión continúa siendo la principal limitación operativa.

8. Lectura crítica de errores, fortalezas y límites

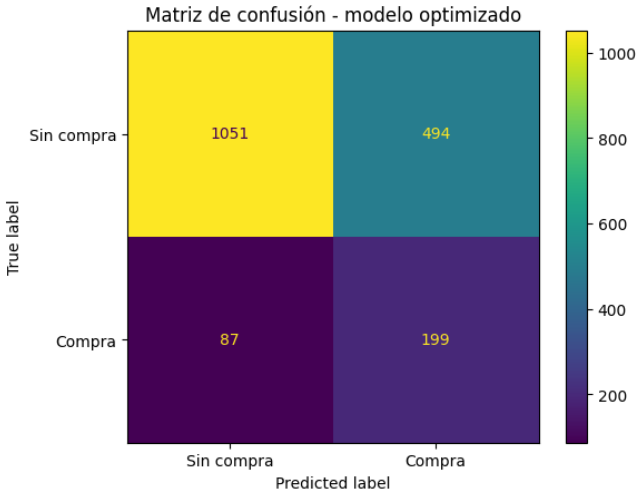


Figura 9: Matriz de confusión final.

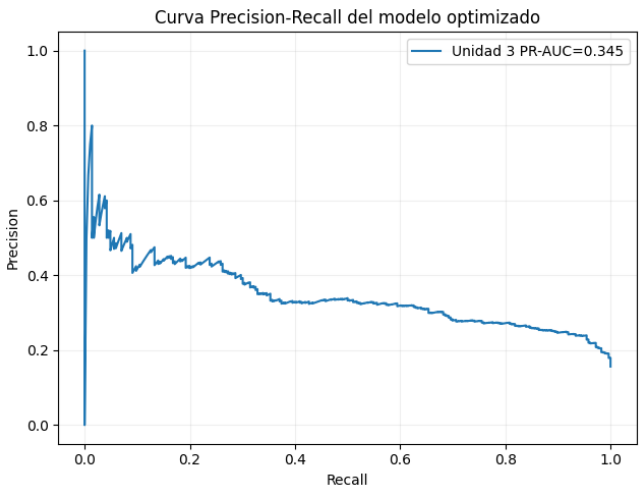


Figura 10: Curva Precision–Recall final.

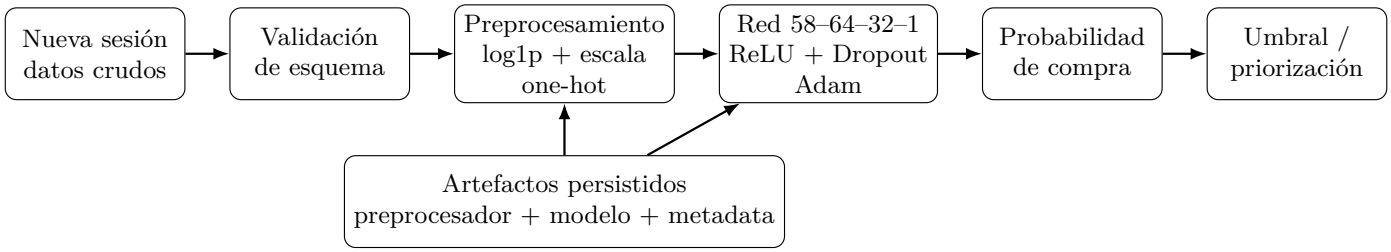
La red identifica 199 de las 286 compras del conjunto de prueba. El costo es generar 494 falsos positivos. Esto tiene una lectura práctica: el modelo es más útil para priorizar o filtrar sesiones que para tomar decisiones irreversibles. Si una campaña tiene costo bajo, un recall cercano a 0,70 puede ser razonable; si contactar falsos positivos es costoso, se necesitaría definir explícitamente el costo de cada tipo de error antes de ajustar el umbral.

La principal fortaleza del modelo es que mejora la calidad global de ordenamiento de la clase positiva frente a una línea base lineal. Sus límites son igualmente claros: precisión moderada, variación entre semillas, ausencia de una verificación temporal de `PageValues` y una única partición 70/15/15. Por eso no presentamos el resultado como una solución lista para producción.

Un resultado importante del proyecto es que aumentar complejidad no produjo mejoras ilimitadas. La arquitectura 64–32 fue útil, pero BatchNorm y LR dinámico no superaron al control. Esto evita una conclusión común pero incorrecta: que un modelo más elaborado necesariamente generaliza mejor.

9. Pipeline final integrado y reproducibilidad

El producto final no es solamente una arquitectura. Se consolidó un flujo en el que la misma lógica de preparación debe aplicarse durante entrenamiento e inferencia.



La reproducibilidad requiere conservar el preprocesador, las categorías raras definidas con entrenamiento, el orden de columnas, el modelo y el umbral. En la etapa de Unidad 3 estos elementos se exportaron como artefactos separados para evitar que una nueva sesión sea transformada de forma distinta a los datos usados durante el entrenamiento.

Cuadro 4: Controles del pipeline final.

Control	Propósito
Split estratificado	Mantener comparabilidad de la prevalencia entre conjuntos.
Preprocesamiento train-only	Evitar fuga de información desde validación o prueba.
Test cerrado	Impedir que las decisiones de ajuste se adapten al resultado final.
Múltiples semillas	Medir sensibilidad a la inicialización y no depender de una sola corrida.
Persistencia de artefactos	Reproducir exactamente la transformación y la inferencia.

10. Trabajo colaborativo, conclusiones y recomendaciones

10.1. Articulación del equipo

La distribución técnica que ya se había documentado en la etapa grupal se conserva como base de organización. Juan Mateo estuvo asociado al seguimiento del modelo base, documentación y lectura de métricas; Ángel estuvo asociado a preparación de datos, validación de calidad, experimentación y diagnóstico. Las decisiones metodológicas, conclusiones y contraste con la regresión logística se revisan de forma conjunta. Para la entrega final.

10.2. Conclusiones

El proyecto demuestra una evolución metodológica trazable. La regresión logística permitió fijar una referencia interpretable; la red base confirmó que había señal no lineal; el aumento de capacidad mejoró PR-AUC pero abrió una brecha de generalización; Dropout permitió conservar desempeño y reducir parte de esa brecha; y las corridas con varias semillas permitieron medir la sensibilidad a la inicialización sin depender de un único entrenamiento.

El modelo final mejora PR-AUC, F1, precision, ROC-AUC y accuracy frente a la regresión logística, aunque no mejora recall. La conclusión, por tanto, no es que la red sea superior en cualquier escenario, sino que ofrece una mejor discriminación global bajo las variables disponibles y con un compromiso operativo todavía abierto entre compradores recuperados y falsos positivos.

La observación pendiente del avance anterior queda cerrada de dos formas: la estabilidad se respalda ahora con tres semillas y el máximo temprano de validación se interpreta también a la luz del posible techo de señal al excluir `PageValues`. Esa variable no debe incorporarse hasta confirmar su disponibilidad temporal.

10.3. Recomendaciones futuras

- validar `PageValues` desde el punto de vista temporal antes de cualquier uso;
- repetir el análisis con particiones temporales o validación cruzada apropiada para confirmar estabilidad;
- definir costos de falsos positivos y falsos negativos antes de optimizar el umbral;
- monitorear deriva de datos y desempeño si el modelo se lleva a un entorno real;
- conservar el pipeline completo como unidad de despliegue, no solo el archivo del modelo.

Declaración sobre uso de IA

La inteligencia artificial se utilizó como apoyo para organizar el documento, revisar consistencia y contrastar conceptos. Los resultados cuantitativos provienen de notebooks ejecutados y las decisiones metodológicas se sustentan en el trabajo desarrollado durante el curso y nosotros los estudiantes.

Referencias

Pérez Borrero, I., & Gegúndez Arias, M. E. (2021). *Deep Learning: Fundamentos, teoría y aplicación*. Universidad de Huelva.
Aggarwal, C. C. (2023). *Neural Networks and Deep Learning: A Textbook* (2nd ed.). Springer.
Géron, A. (2017). *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media.
Sakar, C., & Kastro, Y. (2018). *Online Shoppers Purchasing Intention Dataset*. UCI Machine Learning Repository.
Universidad de La Sabana. (2026). *Guía de actividad – Unidad 3, Fundamentos de Redes Neuronales*.